INSA INSTITUT NATIONAL DES SCIENCES APPLIQUÉES TOULOUSE

Catégorisation de produits

Ateliers-Big-Data

Brendan Guillouet

11 Décembre 2017

Institut National des Sciences Appliquées

Plan de Présentation

Introduction

Étude de données textuelles

Multiple **domaines de recherche** et une très grande variété d'**applications** :

- Recherche d'information.
  - *Moteur de recherche (Google, Yahoo).*
- Traitement Automatique du language.
  - *ChatBot.*
- Reconnaissance de pattern.
  - *Scrawling de page.*
- Analyse de sentiments.
  - *Marketing.*
- Désambiguïsation.
  - *Sécurité.*

La catégorisation de produits

Objectif :

Automatiser la catégorisation des produits dans l'arborescence du site. *(Concours Datascience.net*
https ://www.datascience.net/fr/challenge/20/details)

- 47 Catégories de niveau 1.
- 536 Catégories de niveau 2.
- 5789 Catégories de niveau 3.

Difficultés :

- Gérer des gros volumes de données (**Big Data**) :
  - *dizaines de millions de produits.*
- Données **réelles** :
  - *étape de nettoyage importante.*
- Appréhender un nouveau type de données : **textuelles**.

Les données

Données issues du concours proposé par **Cdiscount** et disponible sur **Datascience**.

Fichier d'apprentissage de 15.786.885 produits.

Champ	Type de données	Description
Identifiant produit	String	Identifiant unique du produit
Catégorie 1	Int	Catégorie de niveau 1
Catégorie 2	Int	Catégorie de niveau 2
Catégorie 3	Int	Catégorie de niveau 3
Description	String	Description produit
Libelle	String	Description courte
Marque	String	Marque du produit

Table 1 – Données Cdiscount.

Exemples de données

Catégorie1	Description
CULTURE - JEUX	playstation 4 et jeu pes 4
CULTURE - JEUX	xbox 360 et call of duty
CULTURE - JEUX	manette pour xbox et playstation 4
JARDIN - PISCINE	grande pelle verte
JARDIN - PISCINE	pompe a eau pour jardin
AUTO - MOTO (NEW)	360 casque avec visière
AUTO - MOTO (NEW)	pompe a eau et gaz

Table 2 – Exemple de catalogue d'apprentissage.

Problématiques

Difficultés :

- **Bruits** liés aux fautes d'orthographes, aux accords, à la conjugaison.
- Nombreux termes **non significatifs**.
- Termes significatifs liés **au contexte**.
- **Transcription** aux outils machine learning.
- Décision liée au **contexte**.
- Traitement **différent** d'une langue à l'autre.

$\Rightarrow$ Étape de pré-traitement des données très importante.

Nettoyage des données

Racinisation (Stemming)

Problème : Des termes peuvent-être écrits de **différentes façons** (accents, conjugaison, genre, pluriels..) et néanmoins avoir le **même sens**.

Solution : Remplacer les mot par leur **racine**.

Exemple :

- épée, épee, epée = epe
- vert, verts, verte, vertes = vert
- mange, manger, mangez, mangent = mang

De nombreux algorithmes différents propre aux langues étudiées
Algorithme utilisé : *Snowball (Porter)*

Les "Stopword"

Problème :

Des termes très usuels, donc non différenciateurs, peuvent perturber l'apprentissage.

Solution :

Lors de l'étape de preprocessing, les mots les plus communs sont supprimés à partir d'une liste de **Stopword** :

(["a", "afin", "ai", "ainsi", "après", "attendu", "au", "aujourd", "auquel", "aussi","autre", "autres", "aux", "auxquelles", "auxquels", "avait", "avant", "avec", "avoir","c", "car", "ce", "ceci", "cela", "celle", "celles", "celui", "cependant", "certain","certaine", "certaines", "certains", "ces", "cet", "cette", "ceux", "chez", "ci",])

$\Rightarrow$ Également propre à la langue !

Autres étape de nettoyages

- Suppression de code HTML (*BeautifulSoup*).
- Suppression de la ponctuation.
- Incrémenter les stopwords avec de la connaissance métier.
- Suppression des caractéristiques numériques (sauf pour les marques)
  $\Rightarrow$ Importance de la connaissance métier !

Illustration - Catégorie ”Téléphonie - GPS”

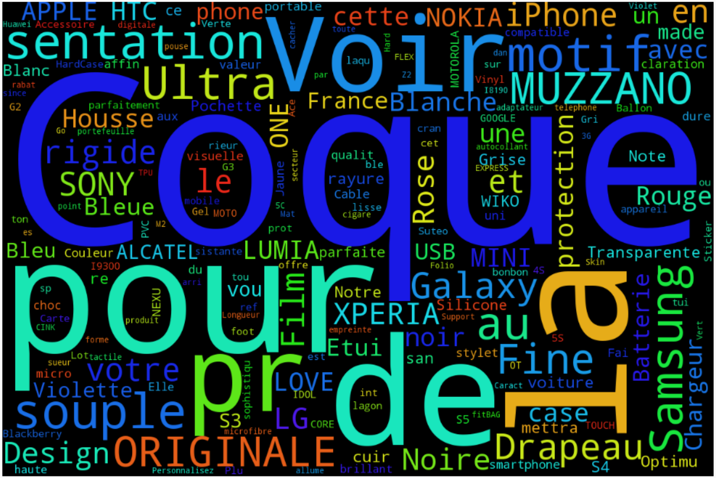

Mots les plus fréquents avant nettoyage.

Illustration - Catégorie "Téléphonie - GPS"

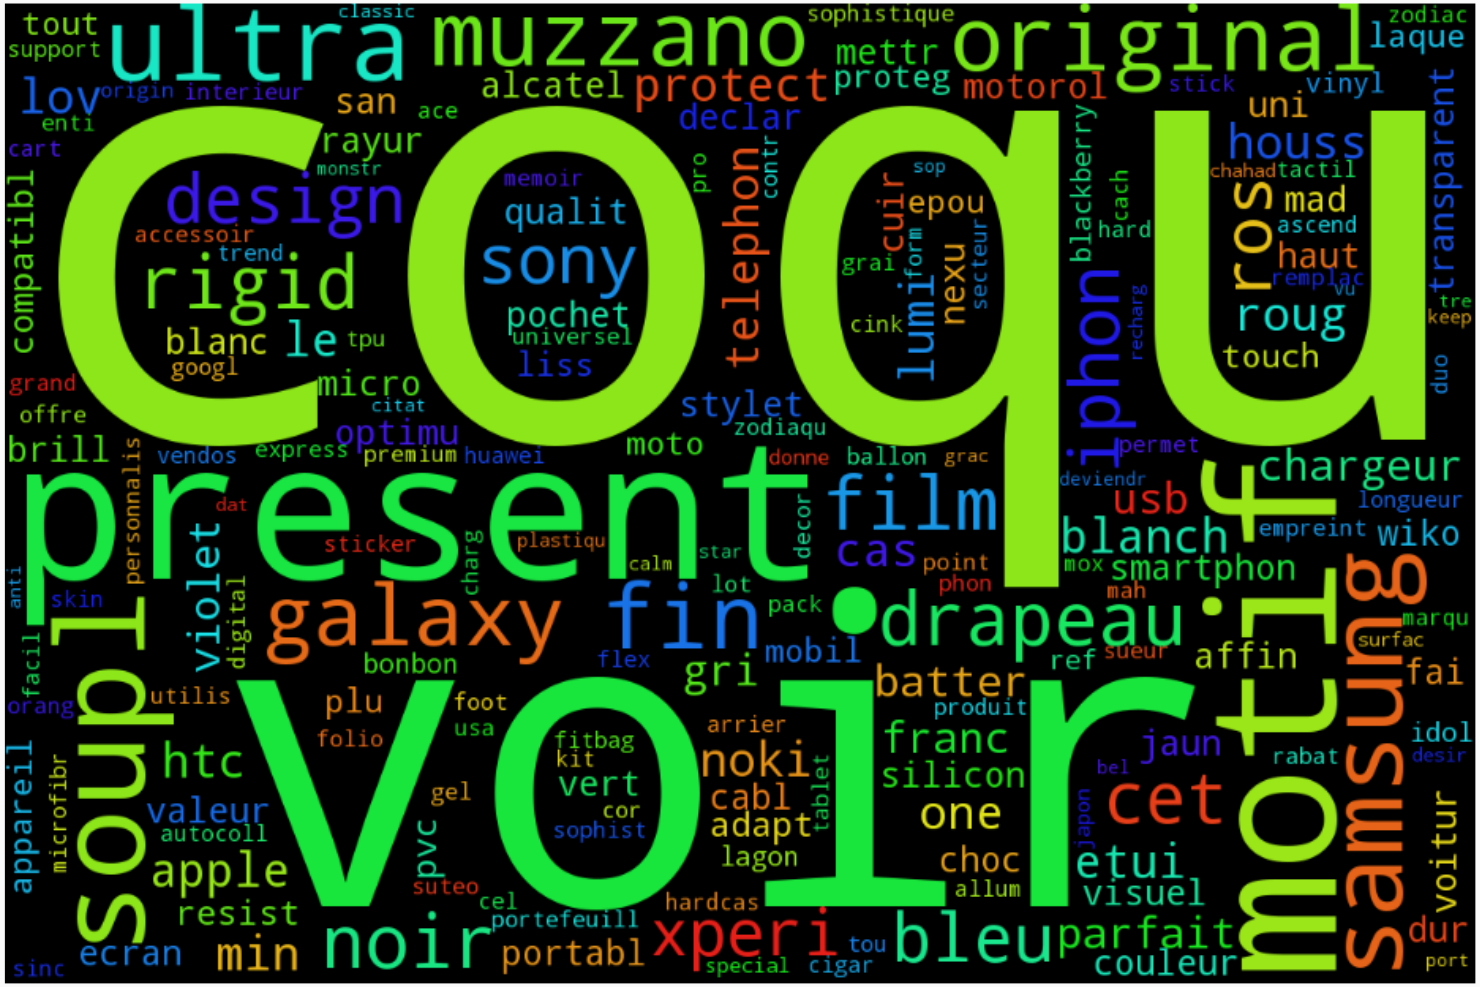

Mots les plus fréquents après nettoyage.

Illustration - Catégorie ”Téléphonie - GPS”

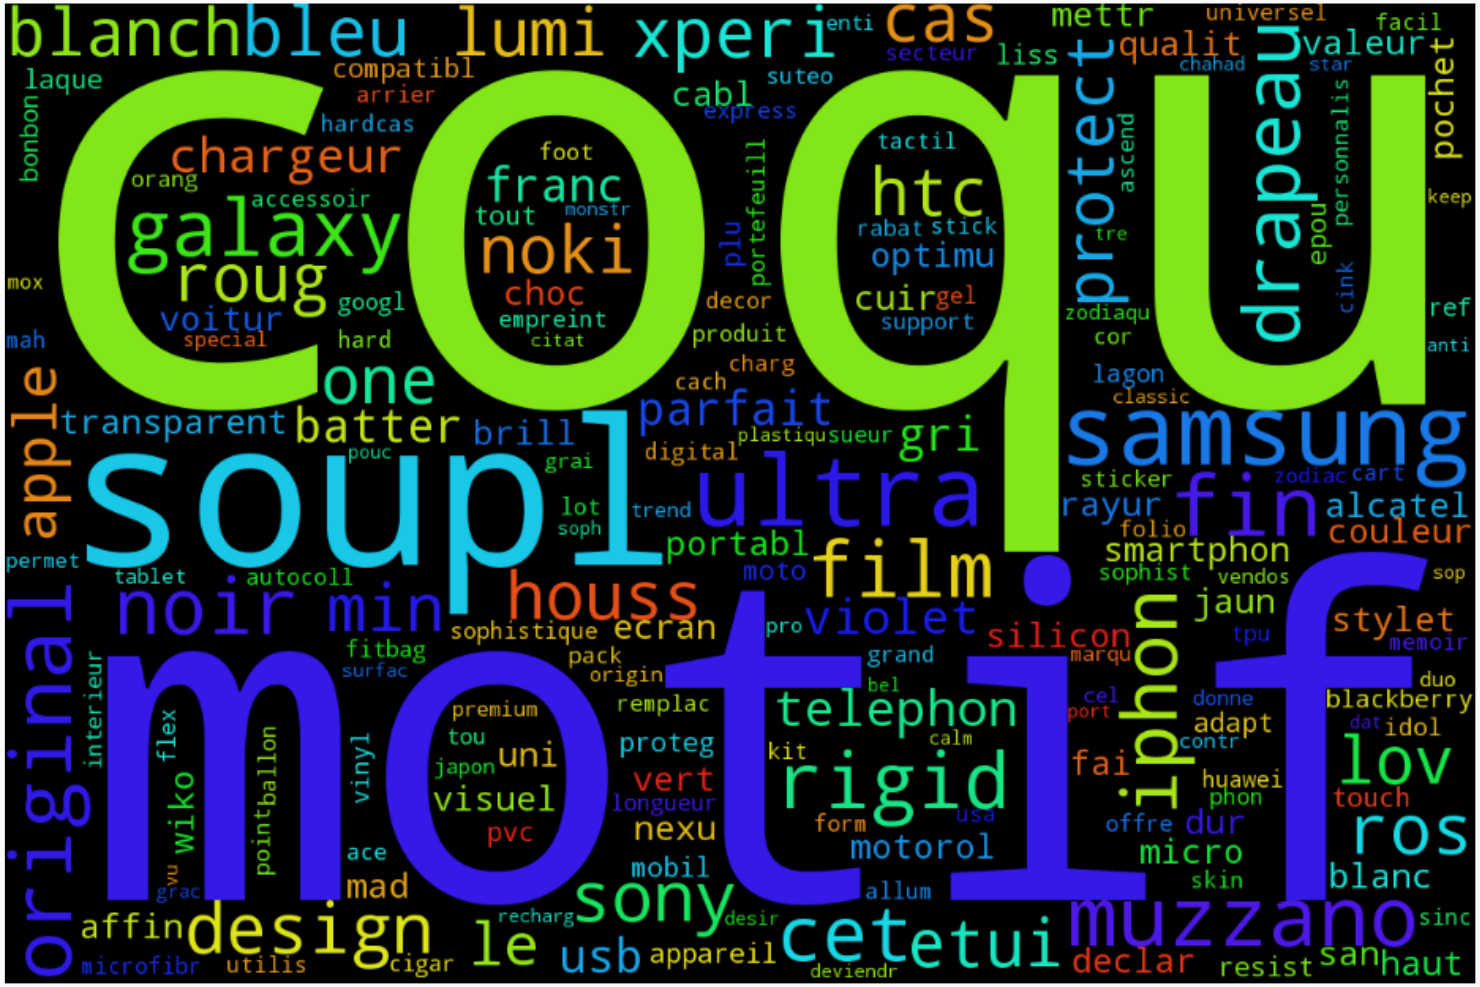

Ajout de stowpords liés au contexte.

Librairies pour le traitement du langage

- **NLTK** *(Python, Spark)* : Traitement du langage (racinisation, stopwords, ...).
- **Lucène** *(Java)* : Librairie d'indexation et de recherche de texte.
- **BeautifulSoup** : Suppression des balises HTML.
- **Regex** : Langage de recherche de texte.

Vectorisation

Objectifs et difficultés

- Transformer la liste de mots sous un format **interprétable** par les différents algorithmes d'apprentissage.
- Gérer le très **grand nombre** de features.
  - Exemple sur 21.543 lignes de la catégorie "TÉLÉPHONIE-GPS"
  - 24.486 mots uniques -> 8.384 après nettoyage.
- Choisir des poids **significatifs**.

Hashage [Weinberger et al., 2009]

Vectoriser les descriptions tout en **réduisant** l'espace de stockage.

$$X \quad \Rightarrow \quad \phi$$

Vecteurs de tailles aléatoires.
Très grand nombre de features.
Taille inconnue

Vecteurs de tailles fixes.
Taille fixé à l'avance : **n_hash**.

- Éviter les collisions.
- Accélérer la vitesse de calcul.
- Non aléatoire.

Hashage [Weinberger et al., 2009]

Definition (Fonction de hashage - 1)

$$h : \mathbb{N} \to \{1, \ldots, n\_hash\}$$
$$i \mapsto j = h(i).$$

Definition (Fonction de hashage - 2)

$$\xi : \mathbb{N} \to \{1, -1\}$$
$$i \mapsto j = \xi(i).$$

Definition (Hashed Feature Map)

$$\phi_j^{\xi,h}(x) = \sum_{i \ s.t. h(i)=j} \xi(i) x_i$$

N-grams

Problématique :

Certains mots n'ont pas le même sens en fonction du contexte.

- *Short de bain* $\neq$ *Short* $\neq$ *bain*

Solution :

On ne considère pas que les mots uniques (*unigram*) mais les couples de mots (*bigram*), ou toutes associations de n mots (n-gram).

- Résout les ambiguïté du langage.
- Explosion de la taille des vecteurs
  - Exemple sur 21.543 lignes de la catégorie "TELEPHONIE-GPS"
  - 8.384 *unigram*, 50.012 *bigram*, 90.854 *trigram*...

TF-IDF

Assigner un **score d'importance** d'un mot, ou d'une association de mots, dans un document **relativement à un ensemble de document**.

- t : mot ou association de mot.
- d : un document.
- D : un ensemble de document.

Definition (Formule Générale TF-IDF)

$$tfidf(t, d) = tf(t, d) \times idf(t, D)$$

- $tf(t, d)$: *Term-Frequency* Nombre d'occurrence du terme t dans le document d.
- $idf(t, D)$: *Inverse-Document-Frequency* Mesure l'importance du terme t dans l'ensemble des documents D.

Formule du TF

Le terme $tf(t, d)$ est généralement défini comme le nombre d'occurrences du terme t dans le document d :

$$tf(t, d) = f_{t,d}$$

Cette définition est celle utilisée dans les librairies *scikit-learn* de *Python* et *Mllib* de *Spark*.

Cependant des variations peuvent exister :

binaire	$0, 1$
normalisation logarithmique	$1 + log(f_{t,d})$
normalisation « 0.5 » par le max	$0.5 + 0.5 \times \frac{f_{t,d}}{\max_{t' \in d} f_{t',d}}$
normalisation par le max	$K + (1 - K) \times \frac{f_{t,d}}{\max_{t' \in d} f_{t',d}}$

Table 3 – Variante du TF (source wikipedia)

Formule de l'IDF

La formule du terme *IDF* varie également d'une implémentation à l'autre.

$log(\frac{N_D}{DF(t,D)})$	
$log(\frac{N_D+1}{DF(t,D)+1})$	*MlLib (Spark)*
$log(\frac{N_D+1}{DF(t,D)+1}) + 1$	*scikit-learn (Python)*

Table 4 – Variante de l'IDF

- N_D : Nombre de documents.
- $DF(t, D)$: Nombre de documents dans lequel le terme t apparaît.

Apprentissage et application de la vectorisation

- Les fonctions de **Hashage** et de **TF-IDF** sont appliquées sur le jeu de données d'apprentissage.
- La même fonction de **Hashage** est utilisée sur le jeu de données test.
- Les termes de **TF** entre un mot t et un document d sont recalculés pour le jeu de données test
- Les termes d'**IDF** calculés lors de l'apprentissage sont réutilisés.

Apprentissage

La régression logistique

- Par défaut, *scikit-learn*, *MlLib* utilisent des algorithmes *"one-vs-all"*
- Dans *scikit-learn* différents solver sont disponible (*liblinear, LBFGS, sag...*).

Solution gagnantes

- Les 4 meilleures solutions ont utilisées des méthodes linéaires Goutorbe et al. [2016]
- Soltutions à pluisieurs niveaux.
  - *On classifie parmi les 1ère catégories..*
  - *...puis parmi les catégories de niveau 4*
- Implémentation de la solution N°2 disponible : https ://github.com/ngaude/cdiscount

TP

TP

4 Notebooks :

- *Atelier-Cdiscount-python-2.ipynb* (py27)
- *Atelier-Cdiscount-python-3.ipynb* (root)
- *Atelier-Cdiscount-pyspark.ipynb* (pyspark)
- *Atelier-Cdiscount-pyspark-pipeline.ipynb* (pyspark)

On définit une fonction de nettoyage :

```
def clean_txt(txt):
    ### remove html stuff
    txt = BeautifulSoup(txt,"html.parser",from_encoding='utf-8').get_text()
    ### lower case
    txt = txt.lower()
    ### special escaping character '...'
    txt = txt.replace(u'\u2026','.')
    txt = txt.replace(u'\u00a0',' ')
    ### remove accent btw
    txt = unicodedata.normalize('NFD', txt).encode('ascii', 'ignore').decode("utf-8")
    ### remove non alphanumeric char
    txt = re.sub('[^a-z_]', ' ', txt)
    ### remove french stop words
    tokens = [w for w in txt.split() if (len(w)>2) and (w not in stopwords)]
    ### french stemming
    tokens = [stemmer.stem(token) for token in tokens]
    ### tokens = stemmer.stemWords(tokens)
    return ' '.join(tokens)
```

que l'on va ensuite appliquer sur chaque description de texte.

Spark possède des Transformer qui permettent d'appliquer ces transformations.

```
STOPWORDS = set(nltk.corpus.stopwords.words('french'))
# Tokenizer
regexTokenizer = RegexTokenizer(inputCol="description", outputCol="tokenizedDescr", pattern="[^a-z_]",
                                minTokenLength=3, gaps=True)
dataTokenized = regexTokenizer.transform(dataEchDF)

# StopWordsRemover q
remover = StopWordsRemover(inputCol="tokenizedDescr", outputCol="tokenizedRemovedDescr",
stopWords = list(STOPWORDS))
dataTokenizedRemoved = remover.transform(dataTokenized)

# Stemmer
STEMMER = nltk.stem.SnowballStemmer('french')

def clean_text(tokens):
    tokens_stem = [ STEMMER.stem(token) for token in tokens]
    return tokens_stem
udfCleanText =  udf(lambda lt : clean_text(lt), ArrayType(StringType()))
dataClean = dataTokenizedRemoved.withColumn("cleanDescr", udfCleanText(col('tokenizedRemovedDescr')))
```

- RegexTokenizer = Regex + Tokenizer.
- Pas de Transformer de stemming.

Fonctions de *hash* et de *tf-idf* séparées.

```
def vectorizer_train(df, columns=['Description', 'Libelle', 'Marque'], nb_hash=10000, stop_words=None):

    #HASH
    # La fonction de FeatureHasher prend en compte le nombre d'apparition de chaque mot.
    df_text = map(lambda x : collections.Counter(" ".join(x).split(" ")), df[columns].values)
    feathash = FeatureHasher(nb_hash)
    data_hash = feathash.fit_transform(map(collections.Counter,df_text))

    # TFIDF
    vec = TfidfVectorizer(min_df = 1,stop_words = stop_words,smooth_idf=True,norm='l2',
        sublinear_tf=True,use_idf=True, ngram_range=(1,2)) #bi-grams
    tfidf = vec.fit_transform(data_hash)
    return vec, feathash, tfidf



def apply_vectorizer(df, vec, columns =['Description', 'Libelle', 'Marque'], feathash):

    df_text = map(lambda x : collections.Counter(" ".join(x).split(" ")), df[columns].values)
    data_hash = feathash.transform(df_text)

    # TFIDF
    tfidf=vec.transform(data_hash)
    return tfidf
```

Fonctions de *hash* et de *tf* sont combinées dans un Tranformer, et la fonction *idf* dans un second.

```
# Term Frequency
hashing_tf = HashingTF(inputCol="cleanDescr", outputCol='tf', numFeatures=10000)
trainTfDF = hashing_tf.transform(trainDF)

# Inverse Document Frequency
idf = IDF(inputCol=hashing_tf.getOutputCol(), outputCol="tfidf")
idf_model = idf.fit(trainTfDF)
trainTfIdfDF = idf_model.transform(trainTfDF)

# application à l'échantillon test
testTfDF = hashing_tf.transform(testDF)
testTfIdfDF = idf_model.transform(testTfDF)
```

Possibilité de combiner les étapes dans un Pipeline.

```
# Regex + Tokenizer
regexTokenizer = RegexTokenizer(inputCol="description", outputCol="tokenizedDescr",
pattern="[^a-z_]", minTokenLength=3, gaps=True)

# StopWord
remover = StopWordsRemover(inputCol="tokenizedDescr", outputCol="stopTokenizedDescr",
stopWords = list(STOPWORDS))

# Stemmer
stemmer = MyNltkStemmer(inputCol="stopTokenizedDescr", outputCol="cleanDescr")

# Indexer
indexer = StringIndexer(inputCol="categorie1", outputCol="categoryIndex")

# Hasing
hashing_tf = HashingTF(inputCol="cleanDescr", outputCol='tf', numFeatures=10000)

# Inverse Document Frequency
idf = IDF(inputCol=hashing_tf.getOutputCol(), outputCol="tfidf")

#Logistic Regression
lr = LogisticRegression(maxIter=100, regParam=0.01, fitIntercept=False, family = "multinomial",
tol=0.0001,elasticNetParam=0.0, featuresCol="tfidf", labelCol="categoryIndex")

# Creation du pipeline
pipeline = Pipeline(stages=[regexTokenizer, remover, stemmer, indexer, hashing_tf, idf, lr ])

# Execution
model = pipeline.fit(dataTrain)
```

Définition d'un Transformer personnalisé.

```
class MyNltkStemmer(Transformer, HasInputCol, HasOutputCol):

    @keyword_only
    def __init__(self, inputCol=None, outputCol=None):
        super(MyNltkStemmer, self).__init__()
        kwargs = self._input_kwargs
        self.setParams(**kwargs)

    @keyword_only
    def setParams(self, inputCol=None, outputCol=None):
        kwargs = self._input_kwargs
        return self._set(**kwargs)

    def _transform(self, dataset):
        STEMMER = nltk.stem.SnowballStemmer('french')
        def clean_text(tokens):
            tokens_stem = [ STEMMER.stem(token) for token in tokens]
            return tokens_stem
        udfCleanText =  udf(lambda lt : clean_text(lt), ArrayType(StringType()))
        out_col = self.getOutputCol()
        in_col = dataset[self.getInputCol()]
        return dataset.withColumn(out_col, udfCleanText(in_col))
```

TP - Résultat - Temps Nettoyage

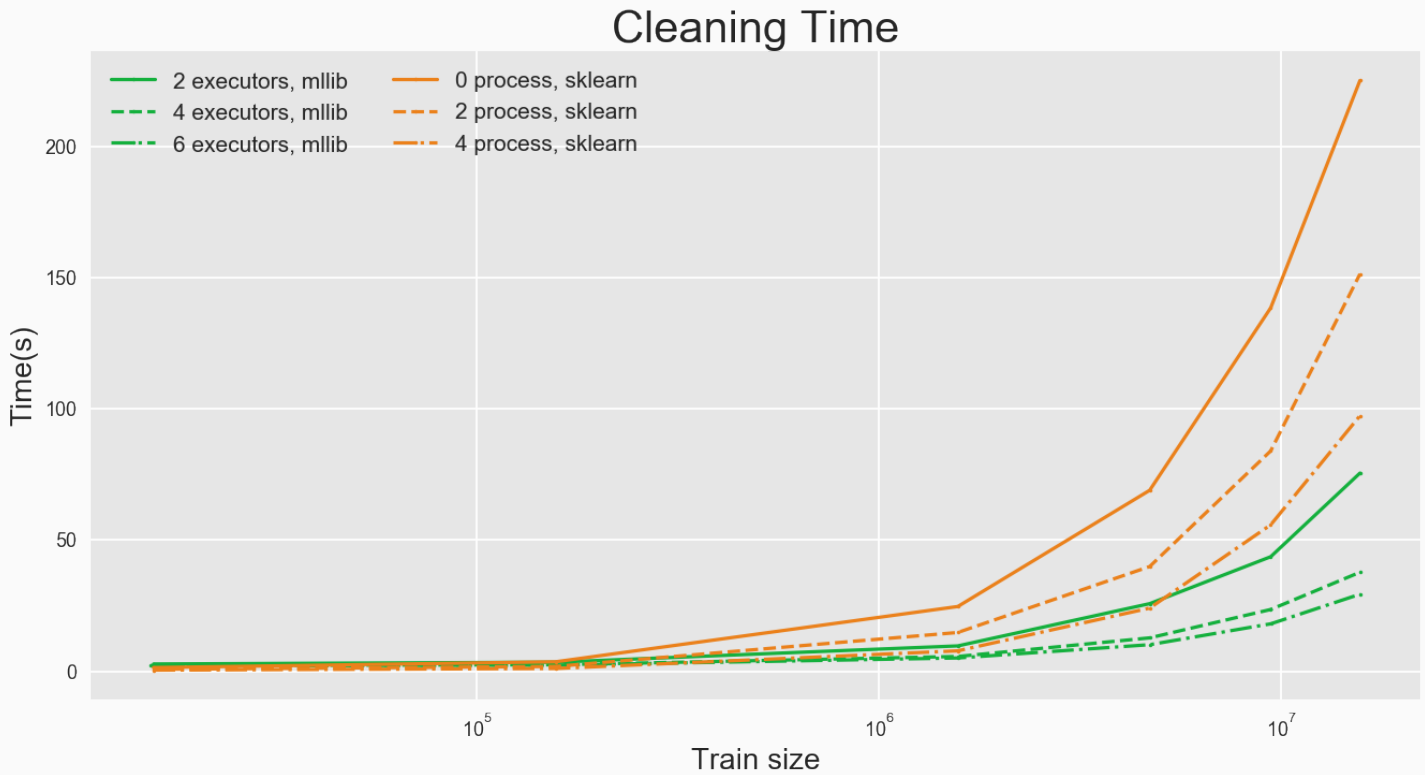

TP - Résultat - Temps Vectorization

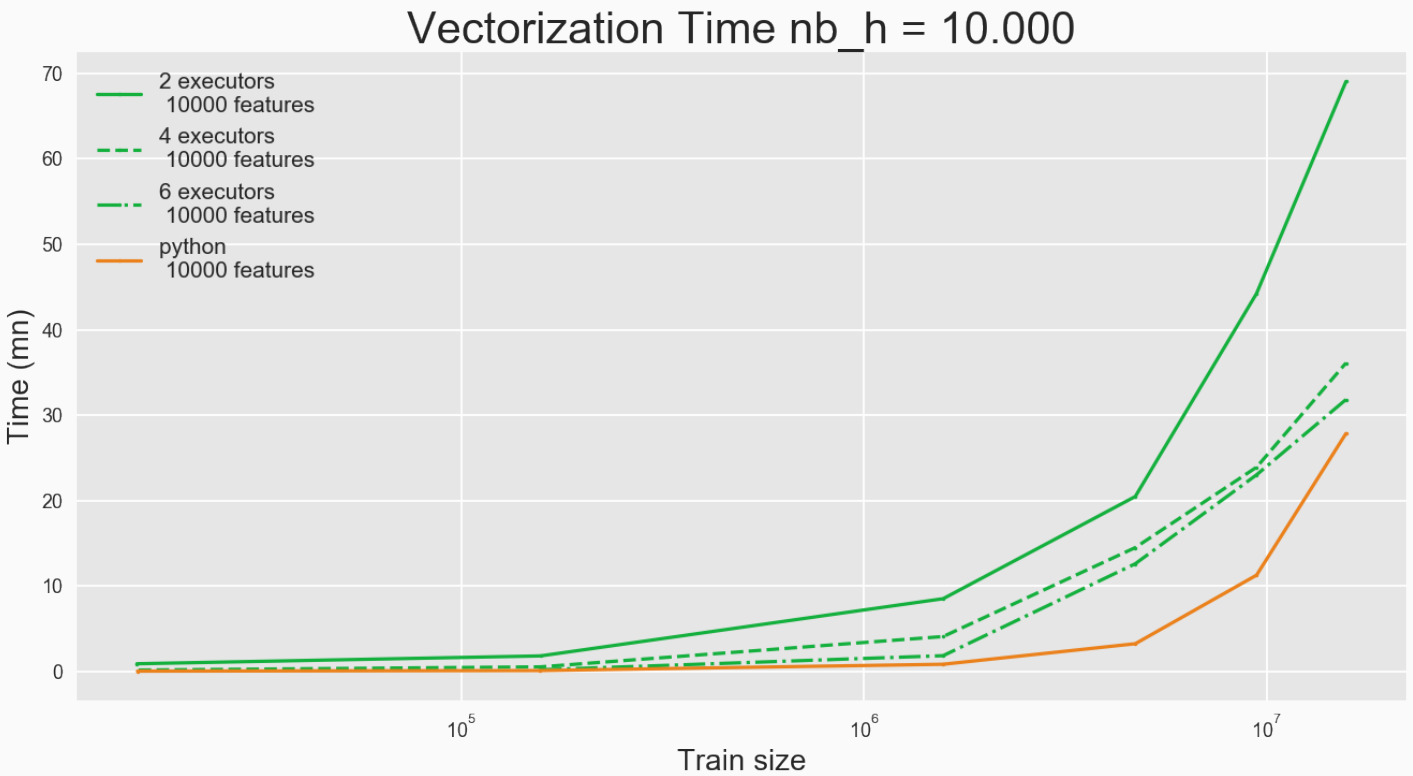

TP - Résultat - Temps Vectorization

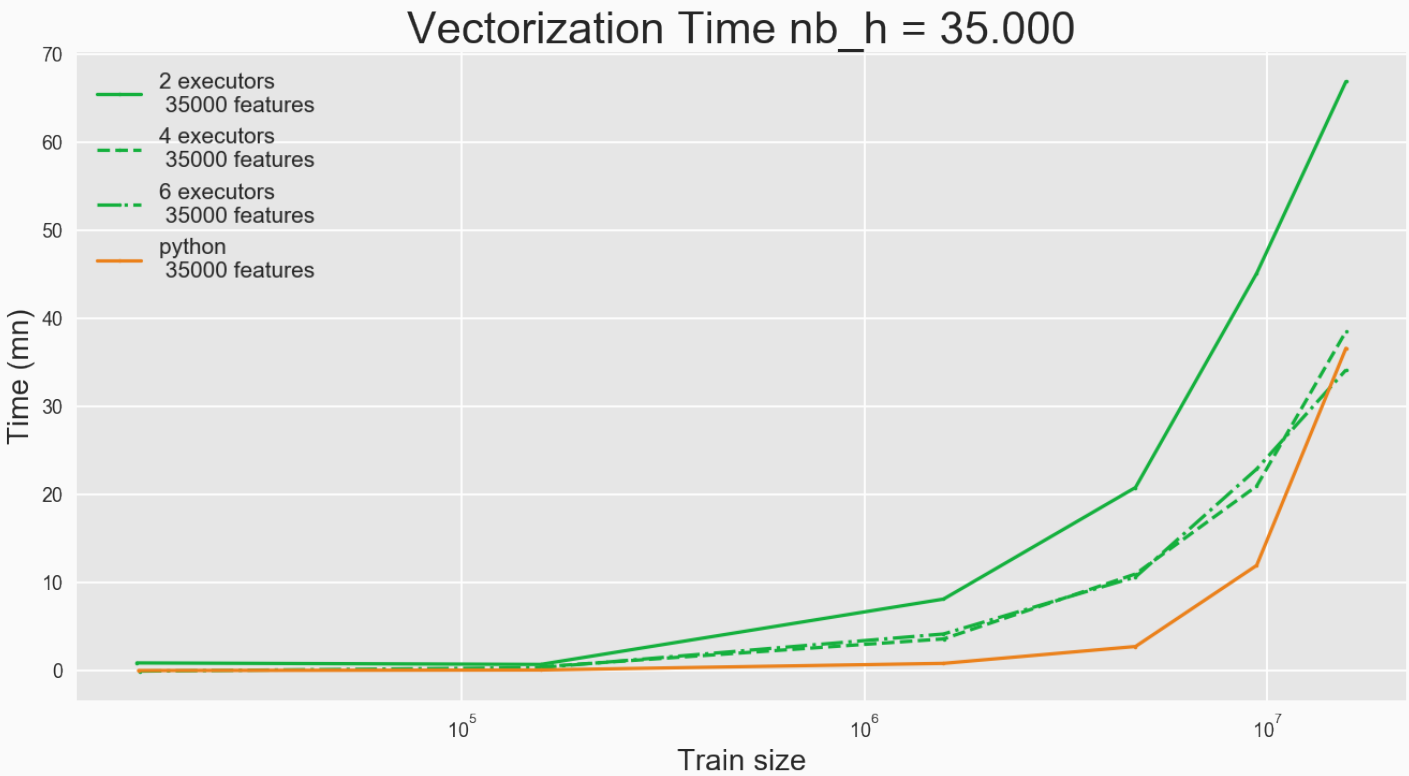

TP - Résultat - Temps Vectorization

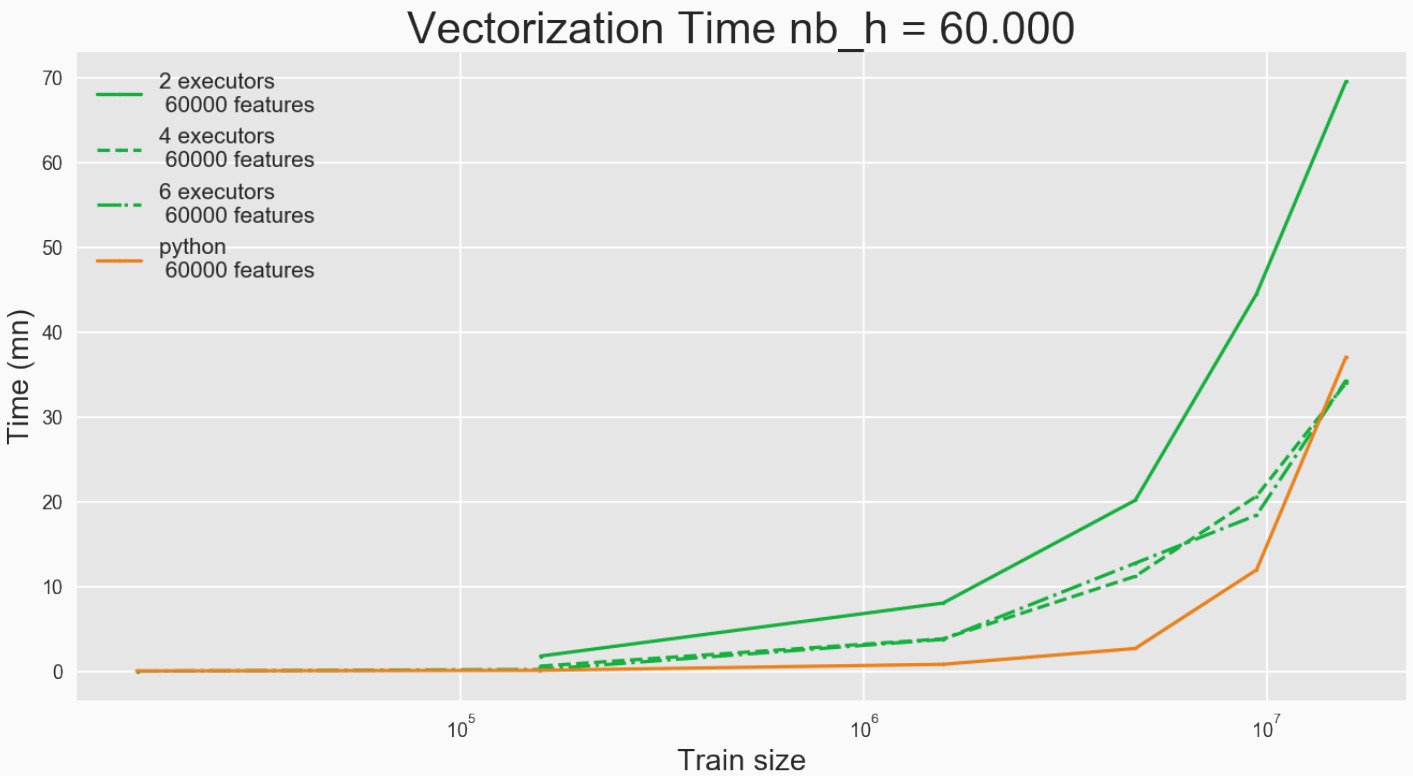

TP - Résultat - Temps Vectorization

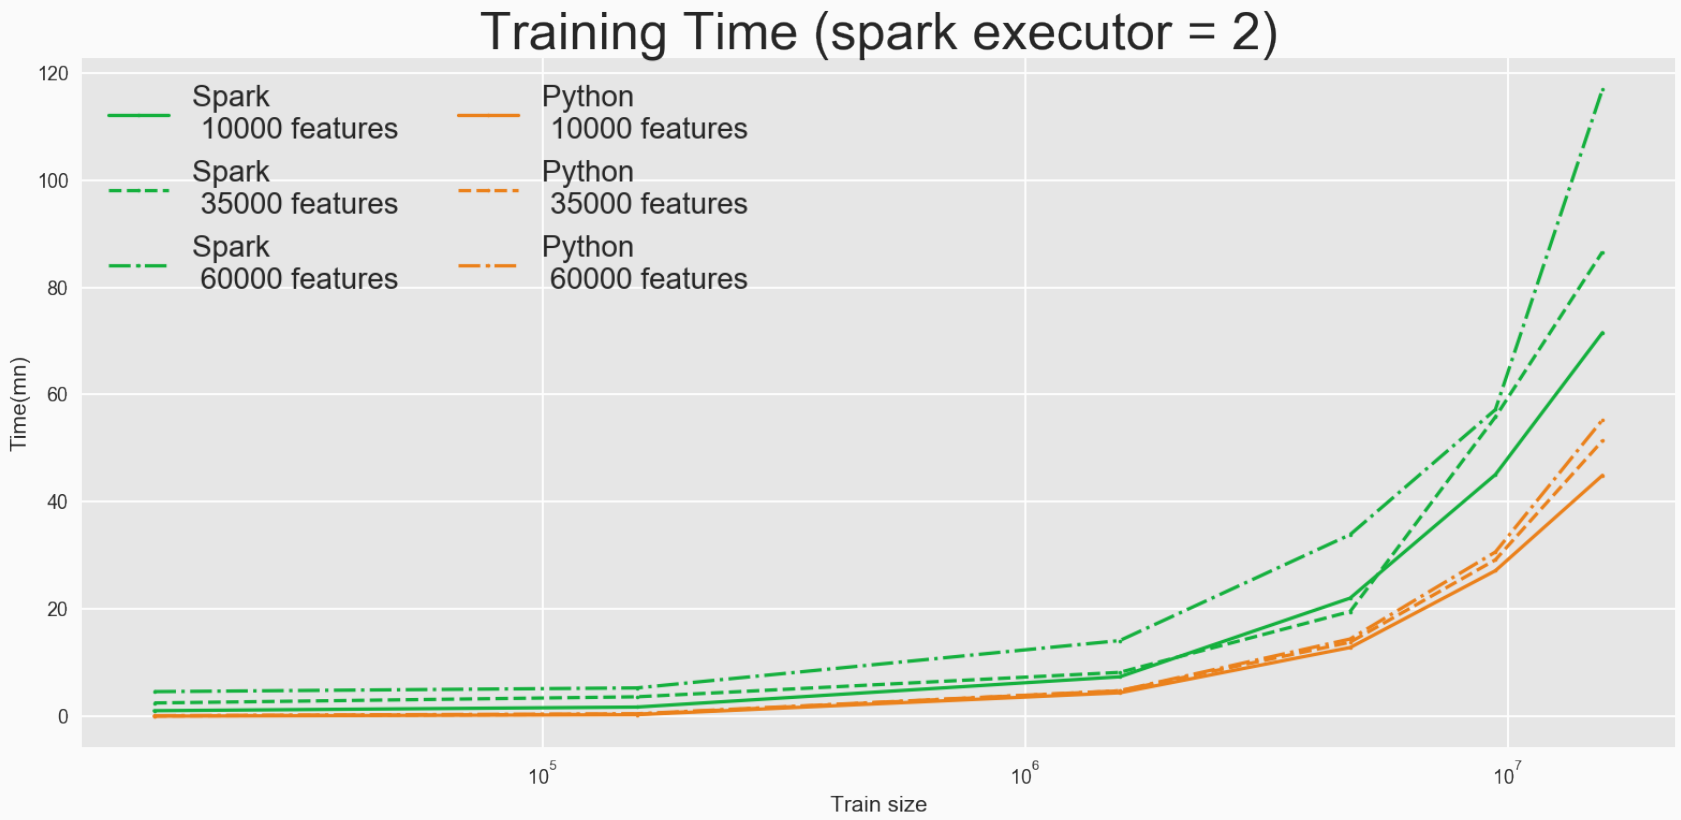

TP - Résultat - Temps Vectorization

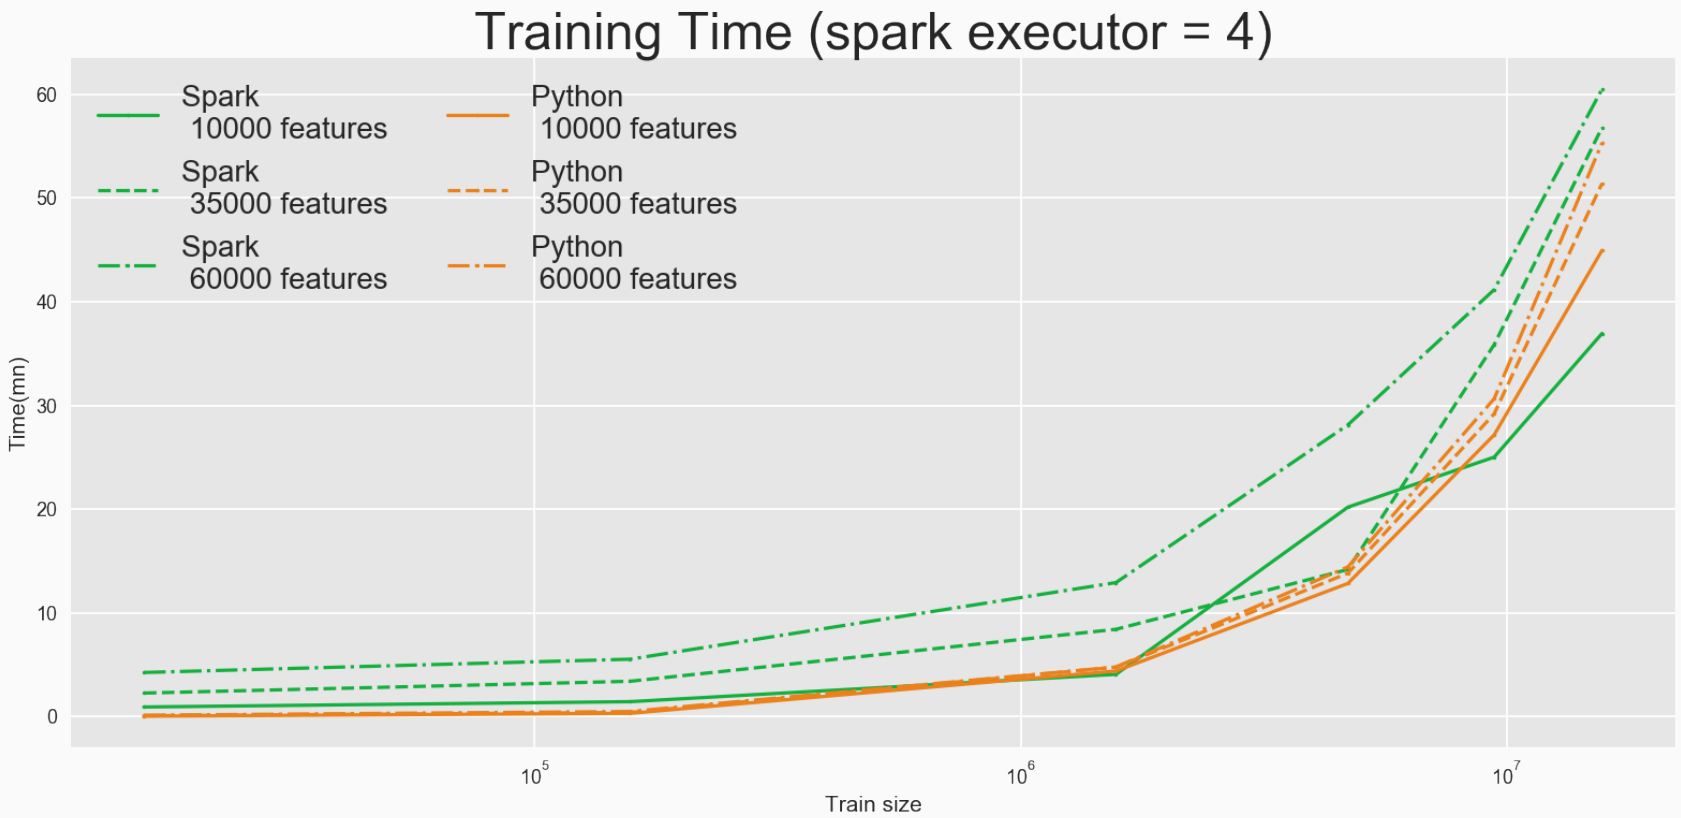

TP - Résultat - Temps Vectorization

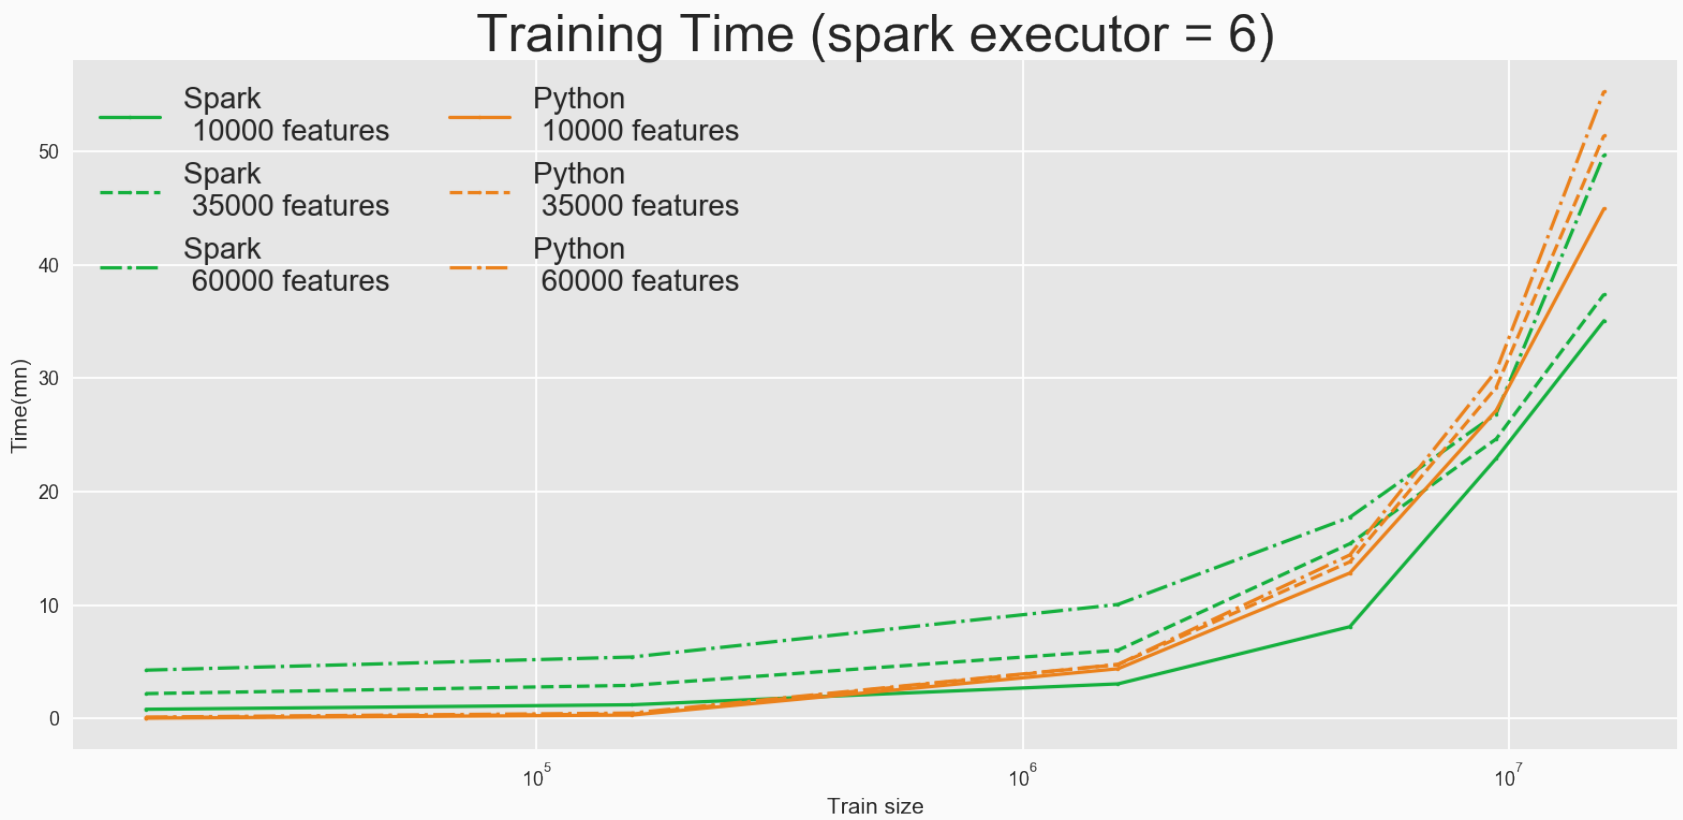

TP - Résultat - Erreur Prédiction

Références

Bruno Goutorbe, Yang Jiao, Matthieu Cornec, Christelle Grauer, and Jérémie Jakubowicz. A large e-commerce data set released to benchmark categorization methods. 2016.

Kilian Weinberger, Anirban Dasgupta, John Langford, Alex Smola, and Josh Attenberg. Feature hashing for large scale multitask learning. In *Proceedings of the 26th Annual International Conference on Machine Learning*, pages 1113–1120. ACM, 2009.